Universal AI Evaluation Engine

Исследование для Freedom Broker CQA

7 ноября 2026 года • Решение для команды на 24 часа

Самое важное

Рекомендуем один сильный LLM Judge по настраиваемой рубрике, проверку доказательств и независимый расчёт баллов. Выборочную независимую перепроверку включать только после измерения её пользы.

- Главный приоритет — совпадение с экспертной разметкой по каждому критерию. До сравнения моделей нужно согласовать N/A и границы шкал.
- В DEV подтверждены 60 чатов и 5 звонков. Чаты короткие: медиана 14 реплик и 981 символ текста. Весь транскрипт следует передавать модели целиком.
- Ключевая находка в звонках: роль operator включает внутреннюю консультацию сотрудников во время удержания клиента. Нужна разметка фаз разговора и предполагаемой аудитории реплик.
- Наличие цитаты проверяется программно; смысловую достаточность оценивают отдельно. N/A нельзя использовать как замену неизвестности.
- Первый модельный эксперимент — GPT-6.1 Sol против Claude Sonnet 5.5 на одинаковой рубрике. Ни одна из моделей пока не измерена на Freedom CQA.

Первые действия команды

Согласовать спорные правила → создать ручной эталон → разделить сценарные семьи → сравнить два single-pass baseline → проверить criterion-wise → измерить net gain выборочного verifier.

Упрощённый fallback

Один запрос выбранной модели, тот же конфиг критериев, строгие проверки, независимая арифметика и статус ручного пересмотра. Без автоматического второго судьи.

Статус доказательств: структура DEV измерена; характерные транскрипты изучены; исследования и тарифы проверены. Accuracy, F1, MAE и latency моделей на DEV ещё не измерены. Платных LLM-вызовов не было.

Документ содержит обновлённое исследование, варианты архитектуры, сравнение моделей, воспроизводимый benchmark и план реализации. Подписанные API-ссылки и персональные данные исключены.

1 Что подтверждено данными DEV

Источник этого раздела — ответ предоставленного DEV API. Структурный анализ охватывает все 65 записей; содержательный разбор выполнен для характерных чатов и фрагментов звонков. Это исследование данных, а не эталонная оценка работы операторов.

Показатель	Подтверждённое значение
Состав	30 RU-чатов, 15 KZ-чатов, 15 EN-чатов; 5 RU-звонков
Длина чатов	11–32 реплики; медиана 14. Текст 769–2206 символов; медиана 981
Длина звонков	45–115 реплик; медиана 75. Текст 3690–5089 символов; медиана 3934
Роли во всём наборе	client 505; bot 315; system 109; operator 339
Схема реплики	speaker, text, timestamp; отдельного turn_id и speaker_id нет
Аудио	Ссылка присутствует у всех 5 звонков; запись не прослушивалась
Эталонные оценки	В ответе API отсутствуют
Структурные проверки	Пустых текстов и точных полных дублей транскриптов не найдено

Находки которые меняют архитектуру

В одном звонке несколько сотрудников участвуют во внутренней консультации, но все их реплики имеют роль operator. Нельзя считать, что каждая такая реплика обращена клиенту, и автоматически штрафовать за её тон либо засчитывать её как объяснение клиенту. Нужны фазы customer-facing, internal-consultation, hold и unknown. При отсутствии speaker_id нельзя надёжно приписать каждую внутреннюю реплику конкретному сотруднику.

Во всех звонках отсутствует отдельное системное событие успешной идентификации. При этом в речи встречается подтверждение прохождения проверки. Валидатор должен допускать семантическое доказательство, не ограничиваясь системной строкой.

В 4 из 5 звонков после события завершения есть ещё одна реплика с разницей около 0,15–0,47 секунды. Это наблюдение о порядке событий, а не установленная причина задержки. Не следует жёстко обрезать транскрипт по этому событию или считать его автоматическим N/A.

Номера сценариев между языками не совпадают по смыслу: первые RU/KZ-чаты посвящены тарифу, первый EN-чат — занятому логину. Группировку нужно делать по содержанию, а не по суффиксу ID.

2 Гипотезы и исследовательская дисциплина

Гипотеза	Проверка	Условие отказа
H1 Явные условия N/A важнее усложнения	Сравнить базовую и уточнённую рубрику	Ошибки applicability не уменьшаются
H2 Single-pass достаточен	Та же модель и рубрика против criterion-wise	Устойчивый выигрыш отдельных запросов
H3 Evidence-first полезен	Порядок evidence → anchor → answer против answer-first	Улучшаются цитаты, но не решения
H4 Targeted verifier окупается	Исправленные ошибки минус испорченные ответы	Net corrections ≤ 0
H5 Оригинал лучше обязательного перевода	Прямой KZ против KZ с переводом как контекстом	Перевод устойчиво улучшает качество без потерь
H6 Transcript-only достаточно для MVP	Разбор случаев, где решение зависит от аудио	Официальная разметка существенно зависит от акустики

Что считается доказательством

Измерено в этом исследовании: состав, поля, размеры транскриптов, события и порядок временных меток DEV. Результаты научных работ относятся к их наборам и моделям. Ожидаемая польза архитектуры Freedom — гипотеза до эксперимента.

Время разработки 24 часа и контроль из 10 новых транскриптов делают особенно опасными подбор решения под единичные примеры и чрезмерное количество сравниваемых вариантов. Главная единица независимости — сценарная семья, а не отдельный перевод или строка «диалог × критерий».

Уровень уверенности

- Высокий: JSON-валидность не равна правильности; существование цитаты не равно смысловой поддержке; арифметика должна быть независимой от LLM.
- Средний: явные рубрики, контроль области ответственности и проверяемые evidence помогут CQA. Прямой сравнительный эксперимент ещё нужен.
- Низкий до benchmark: превосходство конкретной модели, single-pass над criterion-wise, польза ансамбля и выбранных review-триггеров.

Ограничения исходной спецификации

Исходные PDF в рабочей папке отсутствовали. Правила чек-листа прочитаны в локальном критерии_оценки.md и сопоставлены с вашим уточнением о звонках. Некоторые решения в Markdown явно названы интерпретациями команды; их нельзя выдавать за подтверждённый GT организаторов. Ручной эталон команды будет proxy GT, пока нет официальной разметки.

3 Какие исследования определили решение

Явные рубрики вместо общей оценки качества

G-Eval [1] показывает ценность формализованного оценивания, но сохраняет ограничения судьи. MT-Bench [2] выявляет, в частности, предпочтение многословных ответов и другие biases. Для CQA красивое объяснение не должно компенсировать отсутствие ответа на существенный вопрос клиента.

CheckEval [3] исследует декомпозицию оценки на бинарные вопросы на 12 моделях. Это поддерживает атомарные условия внутри критериев, но не доказывает необходимость отдельного API-вызова для каждого условия. Числовые шкалы Freedom при этом сохраняются; сумма произвольных подпунктов не заменяет официальные ступени.

Калибровка важна но требует данных

LLM-Rubric [4] обучает небольшой модуль, согласующий многомерные ответы LLM с людьми. SAJA [5] показывает конкурентоспособность одного структурированного вызова с обучаемой калибровкой. Эти результаты опровергают тезис, что больше вызовов автоматически лучше. Однако объём и независимость Freedom DEV недостаточны, чтобы заранее рекомендовать сложный calibrator. В MVP калибровка означает прежде всего согласование рубрики, few-shot и порогов review.

Доказательства требуют отдельной проверки

ALCE [6] разделяет качество ответа и цитирования. Перенос на CQA: точное совпадение фрагмента обеспечивает синтаксическую валидность, но не доказывает обвинение. Нужны оценка semantic support и проверка противоречащего контекста.

Работа об intrinsic self-correction [7] показывает, что повторное размышление без внешней обратной связи иногда ухудшает ответы. ProCo [8] демонстрирует пользу конкретных проверок условий в других задачах. Поэтому verifier должен проверять основание N/A, роль, порядок событий или границу шкалы; его пользу на CQA нужно измерить.

Многоязычность и динамические критерии

Исследование multilingual judges [9] на 25 языках обнаруживает слабую межъязыковую согласованность; размер модели сам по себе не решает проблему. CE-Judge [10] даёт положительный результат checklist prompting в своих многоязычных задачах. Вместе они обосновывают отдельный KZ benchmark и явные условия, но не обещают конкретной точности.

RubricBench [11] выявляет разрыв между человеческими и автоматически созданными рубриками. Работа о prompt/schema conflicts [12] показывает влияние описаний JSON Schema на решения. Следствие: рубрика утверждается человеком, а prompt, schema и scoring создаются из одной версии конфигурации.

Ни один из этих источников не подтверждает ожидаемый процент качества именно на Freedom CQA. Ссылки [1]–[24] приведены в конце документа.

4 Сравнение архитектур

Подход	Качество N/A и evidence	Затраты и риски
A Single-pass	Хороший baseline с полным контекстом; возможны смешение критериев и подбор цитат под решение	Один запрос; минимальная сложность. Качество определяется рубрикой и моделью
B Criterion-wise	Фокус на одном критерии; независимость решений может порождать противоречия	Около 8 запросов; повторение контекста. Параллелизм снижает wall time, но не токены
C Rules + LLM	Правила гарантируют допустимые значения и расчёт; семантика остаётся за LLM	Обычно один запрос плюс проверки. Regex не должен решать эмпатию или полноту
D Multi-stage	Явные applicability, evidence и score; ранняя ошибка может пройти через все этапы	Несколько последовательных запросов; выше задержка и сложность
E Multi-judge	Может уменьшать случайные ошибки; общее неверное понимание рубрики сохраняется	2–3 оценивания и арбитраж; согласие моделей не равно GT

Все подходы поддерживают новые текстовые критерии при генерации инструкций из конфигурации. Варианты C–E можно комбинировать с A или B. Порядок по точности не установлен: таблица описывает механизм и риски, а не результат эксперимента.

Три варианта для выбора

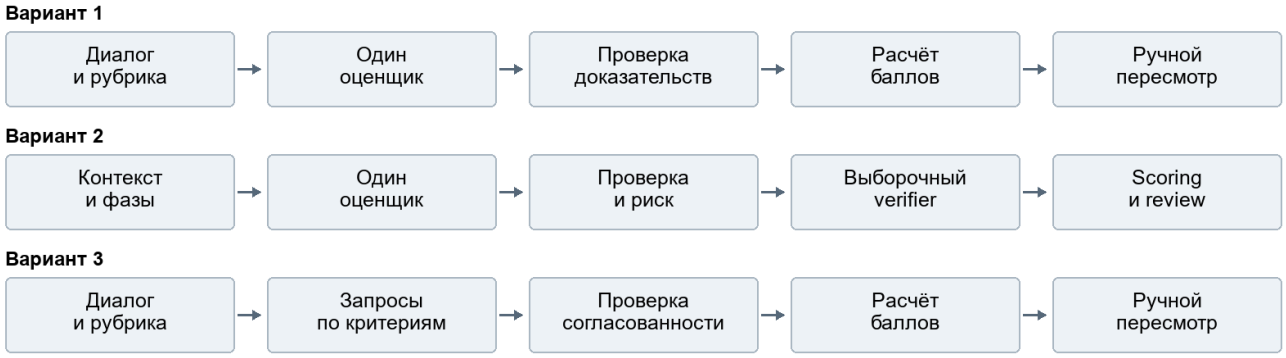
Вариант 1 — baseline и fallback. Полный диалог и чек-лист → один LLM → валидатор → независимый scoring. Минимум движущихся частей; ошибки и спорные решения видит человек.

Вариант 2 — основная рекомендация. Адаптер контекста и фаз → один LLM → валидатор и risk router → выборочная независимая проверка → scoring → ручной пересмотр. Второй вызов включается только после доказательства его пользы.

Вариант 3 — альтернативный эксперимент. Тот же полный диалог → отдельные запросы по критериям → проверка противоречий → scoring. Выбирать при воспроизводимом выигрыше на независимых сценарных группах.

Почему не начинать с максимальной сложности

В DEV нет длинных текстов, требующих retrieval по транскрипту. Для восьми критериев можно сохранить полный контекст. Постоянный ансамбль, отдельный applicability-agent и свободная дискуссия агентов увеличат число мест, где теряются условия рубрики. Проверять дополнительные этапы следует по приросту точности, а не по впечатлению от архитектуры.



5 Основная архитектура и взаимодействие компонентов

Путь одного диалога

1 Адаптер контекста

Сохраняет оригинал, назначает стабильные turn_id, нормализует время и роль. Из событий выделяет передачу оператору, удержание, внутреннюю консультацию и завершение. Не придумывает speaker_id и не считает системное событие полной семантической оценкой.

2 Компилятор рубрики

Из выбранной версии чек-листа создаёт инструкции, допустимые ответы, JSON Schema и параметры scoring. Отдельные чек-листы для chat и voice используют один механизм.

3 Основной оценщик

Получает весь транскрипт, рубрику и при необходимости фрагменты утверждённой KB. По каждому критерию возвращает applicability, наблюдения, evidence, counterevidence, anchor шкалы и ответ.

4 Валидатор

Проверяет полноту набора критериев, значения, ссылки, цитаты, роли, разрешение N/A и согласованность полей. Отказ, обрыв генерации или неправильный формат обрабатываются отдельно от содержательного решения.

5 Выборочный verifier

Проверяет конкретный спорный критерий по полному транскрипту. Сначала формирует независимое решение без первой оценки. Расхождение не означает автоматическую победу второго судьи.

6 Scoring и пересмотр

Код вычисляет итог по версии правил. Человек видит исходную оценку, причины review, evidence и может исправить ответ. Исходное решение AI сохраняется вместе с историей изменений.

Триггеры повторной проверки

Кандидаты: грубое нарушение, неоднозначное N/A, конфликт доказательств, неясная граница шкалы, отсутствие нужного документа KB, подозрительный ASR-фрагмент. Проверять также отрицательные critical-решения с подозрительными признаками и контрольную выборку остальных отрицательных результатов, иначе recall останется неизвестным.

Net corrections = число исправленных ошибок − число испорченных правильных ответов. Именно этот показатель вместе с MAE и покритериальным F1 определяет полезность verifier. Самооценка confidence от LLM не является калиброванной вероятностью.

6 Универсальная конфигурация критериев

Новый текстовый критерий должен работать после изменения данных. Код знает типы ответов и правила валидации, но не содержит условий, привязанных к номерам текущих восьми критериев.

Блок конфигурации	Поля и смысл
Версионирование	checklist_id, version, criterion_id, название, секция, источник правила
Область оценки	subject_role, channel, фаза разговора, требуемые источники данных
Ответ	Boolean, discrete numeric или bounded numeric; allowed_values либо min/max/step
Рубрика	Описание каждого значения, scoring descriptions, границы и исключения
Применимость	allow_na, applicability_conditions, na_conditions, правила недостатка данных
Баллы	weight, mapping ответа в utility; для чисел — явная нормализация
Нарушения	critical_flag, polarity, тип нарушения, влияние на итог по политике
Evidence	Разрешённые роли и типы доказательств; checked_scope для отсутствия действия
Канал и знания	Инструкции chat/voice, зависимости от KB и версии документов
Примеры	Утверждённые development-примеры с происхождением и сценарной группой

Полярность задаётся явно: «Да» для приветствия — положительный ответ, «Да» для грубой ошибки — отрицательный флаг. Вес и оценка не смешиваются: максимум шкалы может отличаться от веса критерия.

Компиляция произвольной рубрики

Детерминированный шаблон перечисляет область ответственности, условия применимости, допустимые значения, описания ступеней и требования к evidence. JSON Schema использует те же ID и значения. Новый критерий не требует fine-tuning, но качество его интерпретации нуждается в проверке. При чрезмерно большом чек-листе критерии можно группировать по размеру контекста без изменения их смысла.

Проверка перед активацией версии

Автоматически: уникальные ID, допустимые веса, шкалы и mapping, описания всех ответов, согласованность N/A, отсутствие циклов зависимостей. Семантически: пересечение ступеней, противоречия, слова «быстро» без границы, требования к недоступным данным, двойной штраф за один дефект. LLM может предложить предупреждение, но не утверждать политику самостоятельно.

Предел универсальности: новый критерий для уже доступного текста работает через конфиг. Новый тип измерения, например акустическая дикция, требует источника аудио и соответствующего адаптера. Это отдельная возможность системы, а не только новая строка рубрики.

7 N A шкалы и повышение точности

Три разных состояния

Состояние	Пример	Поведение
Неприменимо	Общий вопрос не требует идентификации	N/A только по условию рубрики; вес исключается
Действие отсутствует	Обязательное действие не найдено в полном доступном окне	Отрицательное решение с checked_scope
Не установлено	Начало разговора отсутствует или скрыт значимый фрагмент	review_status отдельно; не превращать автоматически в N/A

Если формат сдачи требует обязательный ответ, использовать заранее зафиксированную политику допустимого решения и отдельно показывать неопределённость. Нельзя улучшать MAE, молча исключая трудные диалоги.

Числовая шкала как последовательность проверок

Для консультации определить существенные вопросы клиента, ответы оператора, корректный следующий шаг и незакрытые части. Затем выбрать anchor официальной шкалы. Не снижать критерий 6 за неполноту, если она относится к критерию 4; не повышать полноту за многословие. Контрастные примеры особенно полезны для границ 15/20 и 4/7/10.

Расчёт по доступной спецификации

Итог = $100 \times \Sigma(w_i \times u_i) / \Sigma w_i$ по применимым критериям. Для текущих бинарных критериев u = 1 или 0; для текущих числовых шкал u = ступень / максимум шкалы. Критерий 6 со ступенью 7 и весом 15 даёт 10,5 до перераспределения N/A.

При нулевом знаменателе итог не рассчитывается. Округлять только итог, используя согласованное правило. Грубая ошибка — отдельный флаг без обнуления, пока официальная политика не требует другого. Для новой шкалы с ненулевым минимумом или обратной направленностью нужен явный mapping в utility.

Few shot и оптимизация по ошибкам

Начать с нескольких контрастных development-примеров: N/A против «Нет», обрыв против закрытия оператором, корректный следующий шаг против неполной консультации. После каждого прогона классифицировать ошибки, менять один фактор и проверять на calibration. Не добавлять исключения по conversation_id.

База знаний

Небольшая утверждённая KB нужна для тарифов, регламентов, идентификации и маршрутов эскалации. Хранить продукт, юрисдикцию и период действия. Для 24 часов достаточно простого поиска по малому корпусу. Отсутствие найденного подтверждения не доказывает ошибку оператора. Реплики бота дают контекст, но не являются авторитетным справочником.

8 Достоверность доказательств

Синтаксическая валидность

Модель ссылается на turn_id и при необходимости диапазон символов. Отображаемую цитату лучше извлекать из оригинала программно. Если возвращается текст цитаты, проверять точное совпадение после ограниченной нормализации Unicode и пробелов. Нечёткое совпадение может потерять отрицание или смену субъекта; оно не должно автоматически подтверждать нарушение.

Проверить существование реплики, допустимость span, роль, фазу разговора и timestamp. Событие system может подтверждать процедуру, реплика client — недовольство, сообщение до передачи оператору — уже известную потребность. Универсальное требование «все доказательства только от operator» неверно.

Смысловая достаточность

Проверить, что цитата поддерживает именно выбранный ответ, покрывает все необходимые условия и не опровергается дальнейшим контекстом. Фраза «проверю личность» не равна завершению проверки; подтверждение после раскрытия не исправляет порядок событий. Наличие клиентских данных в разговоре не равно их разглашению оператором.

Подтверждение отсутствия действия

Чтобы утверждать «не представился», нужно установить обязанность представиться, первое речевое действие, полноту доступного фрагмента и отсутствие представления в этом окне. Для звонка первое действие может быть разбито ASR на несколько соседних записей. Сохранять исходные spans, но оценивать связный речевой ход, если это согласовано рубрикой.

Чтобы утверждать «не ответил на второй вопрос», нужно сослаться на вопрос и проверить всю последующую релевантную часть, включая ответы другими словами. checked_scope показывает область проверки, но не является самостоятельным доказательством отсутствия.

Противоречия и область слышимости

Хранить supporting и counterevidence. Внутреннее обсуждение во время удержания нельзя засчитывать как ответ клиенту без подтверждения его слышимости. Поле audience должно допускать unknown: API не даёт акустического доказательства того, что клиент слышал внутренний фрагмент. При отсутствии устойчивой идентификации сотрудников оценивать подтверждённую клиентскую часть либо направлять персональную атрибуцию на review.

Human in the loop

Показывать AI-ответ, исходные реплики, основание шкалы, причины неопределённости и версию рубрики. Исправление человека сохранять отдельным событием с причиной и временем; затем пересчитывать итог. Нельзя перезаписывать исходный AI-ответ, иначе исчезнут данные для анализа ошибок и будущей калибровки.

9 Модели стоимость и инфраструктура

Проверенные кандидаты на 7 ноября 2026 года. Ни качество Freedom CQA, ни latency для них ещё не измерены. Пример цены: 6000 входных и 1500 оплачиваемых выходных токенов, без дополнительных вызовов, аудио, региональных надбавок и cache-write. Источники [14]–[19].

API модель	USD за 1M in / out	Цена примера	Роль в эксперименте
GPT-6.1 Sol	2 / 10	$0,027	Основной single-pass кандидат
Claude Sonnet 5.5	2 / 10	$0,027	Независимый кандидат другого семейства
Claude Opus 5.5	4 / 20	$0,054	Более дорогой selective verifier
Gemini 3.1 Flash-Lite	0,25 / 1,50	$0,00375	Дешёвый baseline
GPT-6 Luna	0,10 / 0,50	$0,00135	Контроль стоимости и сложных ошибок

Structured Outputs поддерживают ограничения схемы, но не смысловую правильность. У API есть ограничения JSON Schema, отказы и незавершённые ответы. Полная стоимость считается из usage всех запросов; reasoning-токены учитывать по правилам биллинга провайдера. Один текст имеет разную токенизацию у моделей.

Цена диалога = сумма по запросам (Tinput × Pinput + Toutput billed × Poutput) / 1 000 000. Для тарифа $2/$10 основной запрос примера стоит $0,027; verifier на 6000/500 токенов — $0,017. При условных 25% перепроверок средняя цена $0,03125. Это сценарий, не измеренная стоимость DEV.

Локальный кандидат	Память только весов	Применение и ограничения
Qwen3.5-27B	≈54 GB BF16 / 13,5 GB INT4	Универсальный open-weight кандидат; для INT4 ориентир GPU 24–32 GB при ограниченном контексте
Qwen3-32B	≈64 GB BF16 / 16 GB INT4	Явно заявлены RU, EN, Kazakh; более зрелый стек
ISSAI Qwen3.5-9B-Kazakh	≈18 GB BF16 / 4,5 GB INT4	KZ challenger; ориентир 12–16 GB GPU для короткого quantized контекста

Оценки памяти не включают KV-cache, scales и runtime; это не гарантия размещения. Источники моделей [20]–[23]. Локальный constrained decoding доступен через совместимый сервер, например vLLM [24]. Локальная цена включает аренду, простой и обслуживание; скорость измеряется на выбранном GPU.

Все кандидаты могут получать новые рубрики через prompt. Заявленная поддержка казахского или специализация ISSAI не доказывают лучшее CQA-оценивание. Сравнить сначала Sol и Sonnet; локальную модель включать только при готовой инфраструктуре. Latency измерять как end-to-end p50/p95 при одинаковой concurrency.

10 Языки и голосовой канал

RU KZ EN и смешанная речь

Оценивать оригинал, сохранять цитаты на исходном языке. Определять язык клиента по его содержательным репликам; язык интерфейса, IVR и системных сообщений не равен языку запроса. Code-switching сам по себе не считается ошибкой. В DEV все звонки помечены RU, хотя есть события переключения языка и искажённые многоязычные фрагменты.

Перевод можно проверять как дополнительный контекст для KZ. Нельзя оценивать по переводу язык приветствия, грамотность и формулировки: перевод способен исправить дефекты. Согласованность между языками измерять только для действительно эквивалентных сценариев; общая тема не гарантирует одинаковый GT.

Transcript only и transcript plus audio

Признак	По транскрипту	С аудио
Полнота консультации	Обычно наблюдаема по вопросам и ответам	Можно уточнить спорные ASR-фрагменты
Логика и ясность	Частично наблюдаемы с учётом ASR	Добавляются перебивания и контекст произнесения
Паузы	Одного timestamp на реплику недостаточно	Нужны речевые интервалы и роли
Дикция темп разборчивость	Надёжно не наблюдаемы	Нужна отдельная согласованная рубрика
Сложность за 24 часа	Низкая при готовом транскрипте	Выше из-за декодирования и проверки сегментов

Критерий 4 звонка проверяет полноту и корректность консультации; критерий 6 — логику разговора, понятность речи и управление паузами. Это отдельная версия рубрики voice, а не условия по номеру критерия в Python. Акустические признаки не добавляются в оценку, если официальная рубрика и доступные данные их не предусматривают.

ASR и события

Разница времён начала соседних реплик не равна тишине: она включает речь участников. Остановка записи не доказывает молчание оператора. В API нет интервалов начала и конца речи, ASR-confidence и идентификаторов отдельных сотрудников. Сохранять эти ограничения в evidence metadata.

Careless Whisper [13] подтверждает возможность добавления ASR отсутствующего текста. Это не измерение конкретного DEV ASR. Подозрительную фразу нельзя ни автоматически штрафовать, ни автоматически списывать на распознавание. Для критического решения нужен audio review или явно отмеченная неопределённость.

За 24 часа: транскрипт — основа, ссылка на аудио — способ проверить спорный участок. Автоматический анализ дикции и темпа отложить. Пять RU-звонков использовать как исследовательские кейсы; они не подтверждают качество KZ/EN voice и не дают устойчивой статистики.

11 Воспроизводимый benchmark

Разделение и ручной эталон

Сначала вручную определить сценарные семьи по содержанию: переводы, близкие шаблоны и связанные обращения. Не группировать по одинаковым номерам ID. Общая тема также недостаточна: нужна близость ситуации и последовательности действий. Сохранять все производные примера в одной части.

Рабочая пропорция — примерно 40% development, 30% calibration, 30% locked test по группам, с учётом RU/KZ/EN. Фактические числа назначаются после группировки. Сценарии, уже разобранные в спецификации или использованные для изменения правил в этом исследовании, относятся к development. Звонки, на которых найдены архитектурные особенности, не выдавать за совершенно независимый финальный тест.

Предпочтительно разметить все 65 диалогов. Минимальный пилот — 24–30 диалогов из разных семей. Два человека независимо размечают хотя бы calibration/test, не видя ответов моделей; KZ проверяет компетентный читатель. Сохраняются ответ, N/A, evidence, спорность рубрики и необходимость KB. После независимой разметки проводится adjudication. Это proxy GT, а не официальные ответы жюри.

Метрика	Как считать и что дополнительно показать
MAE итога	Абсолютная ошибка на 0–100; медиана, максимум и ошибки отдельных диалогов
Macro-F1	По каждому дискретному критерию; затем среднее по критериям. Показать support классов
N/A Accuracy	Только там, где N/A разрешён; дополнить precision/recall N/A
Числовые шкалы	Exact match и нормированная MAE; для непрерывных значений F1 заменить MAE/tolerance
Critical precision/recall	Показать TP/FP/FN; без положительных примеров recall не определён
Evidence validity	Доля допустимых ссылок, ролей и точных spans
Evidence support	Ручная оценка достаточности и отсутствия противоречий
Coverage и review	Доля завершённых оценок и доля пересмотров; сложные случаи не скрывать
Latency и cost	End-to-end p50/p95; стоимость всех запросов, retries и reasoning
Stability и языки	Смена решений при повторе; RU/KZ/EN отдельно; эквивалентные пары отдельно

Ошибки критериев могут компенсироваться в итоговом балле, поэтому MAE нельзя использовать одну. Сравнения — парные, bootstrap по сценарным группам. При малом числе групп показывать широкую неопределённость и абсолютное число ошибок. Abstention не должен незаметно улучшать показатели за счёт исключения трудных случаев.

12 Порядок экспериментов и решение за 24 часа

Шаг	Эксперимент	Решение
E0	Согласовать рубрику, разметку и split	Зафиксировать цель измерения
E1	Sol против Sonnet в single-pass	Выбрать начальную модель
E2	Evidence-first против answer-first	Оставить полезный формат решения
E3	Single-pass против criterion-wise	Проверить пользу отдельных запросов
E4	Лучший простой вариант с verifier и без	Измерить net corrections
E5	Few-shot; отдельно KB	Выделить причину улучшения
E6	Новые критерии и изменения чек-листа	Проверить реальную универсальность
E7	Один прогон закрытого теста	Получить независимую оценку

E1–E6 выбираются по development/calibration. Locked test не используется для очередной правки. Сохранять model ID, reasoning settings, prompt/schema/checklist/KB versions, input hashes, split seed, usage и retries. Минимальная temperature не гарантирует детерминизм и должна поддерживаться выбранным API.

Проверка гибкости

После фиксации движка добавить новый критерий через конфиг, например наличие обещания гарантированного дохода. Заранее определить его рубрику и независимые метки. Изменение только веса должно менять итог, но не семантический ответ; новая шкала ограничивает значения; запрет N/A отражается в schema; chat→voice меняет инструкции без правок кода.

Критерии выбора

До эксперимента установить практический порог улучшения, например 1 балл MAE из 100 как рабочее решение команды. Принимать усложнение при выигрыше на нескольких независимых группах без явного ухудшения KZ и critical precision/recall. Если разница неубедительна, выбрать более простой вариант. Считать также исправленные и испорченные verifier ответы.

Распределение суток

0–4 часа: рубрика, фазы звонков, группировка и начало независимой разметки. 4–9: baseline, компилятор конфигурации, валидатор и scoring. 9–15: модельное сравнение и ablations. 15–20: выбранная конфигурация, review и проверка новых критериев. 20–24: закрытый прогон, исправление только технических сбоев, подготовка демонстрации. Разметка идёт параллельно при наличии второго участника.

Не реализовывать в MVP: fine-tuning, RL, сложный calibrator, постоянный ансамбль, собственный ASR, анализ дикции и крупную retrieval-инфраструктуру. Plan B: тот же движок с лучшей проверенной моделью; criterion-wise включать только для критериев с доказанным выигрышем. Главный риск — неверная трактовка официальной рубрики, которую не исправляет увеличение числа моделей.

13 Научные источники

[1] G Eval — EMNLP 2023

Rubric-based оценивание и согласованность с людьми; перенос результатов на CQA требует проверки.

[2] Judging LLM as a Judge — MT Bench and Chatbot Arena

Возможности сильных оценщиков и position, verbosity, self-enhancement biases.

[3] CheckEval — EMNLP 2025

Декомпозиция рубрики на бинарные вопросы и сравнение 12 моделей.

[4] LLM Rubric — ACL 2024

Калибровка многомерных ответов LLM по человеческой разметке.

[5] SAJA — ACL Industry 2026

Один структурированный вызов и обучаемая калибровка; результаты зависят от задачи и label budget.

[6] ALCE — EMNLP 2023

Разделение качества ответа, корректности цитат и полноты поддержки утверждений.

[7] Large Language Models Cannot Self Correct Reasoning Yet

Ограничения intrinsic self-correction без внешней обратной связи; ICLR 2024.

[8] Key Condition Verification и ProCo — EMNLP 2024

Положительные результаты целевой проверки условий в QA и reasoning-задачах.

[9] How Reliable is Multilingual LLM as a Judge

Пять семейств моделей, пять задач и 25 языков; слабая межъязыковая согласованность.

[10] Checklist Engineering Empowers Multilingual LLM Judges

Training-free checklist prompting в многоязычном оценивании.

[11] RubricBench — ACL 2026

Ограничения автоматически сгенерированных рубрик относительно экспертных.

[12] Your Prompt Is Not the Only Prompt — 2026

Влияние описаний схемы на классификацию и риск конфликтов prompt/schema; препринт.

[13] Careless Whisper — FAccT 2024

Риски добавления отсутствующего текста при распознавании речи. Не аудит ASR Freedom.

14 Документация и основания рекомендаций

[14] OpenAI API Pricing

Стандартные тарифы GPT-6.1 Sol и GPT-6 Luna. Проверены при исследовании; цена зависит от режима.

[15] Claude API Pricing

Тарифы Claude Sonnet 5.5 и Opus 5.5 без дополнительных модификаторов.

[16] Gemini API Pricing

Тариф Gemini 3.1 Flash-Lite. Пример стоимости не является измерением DEV.

[17] OpenAI Structured Outputs

Поддерживаемые схемы, ограничения и обработка ответа.

[18] Claude Structured Outputs

Native schema output и ограничения JSON Schema.

[19] Gemini Structured Outputs

Поддержка подмножества JSON Schema.

[20] Qwen3.5 27B model card

Первичный источник по open-weight кандидату.

[21] Qwen3 32B model card

Модель для локального сравнительного эксперимента.

[22] Qwen3 официальный список языков

Включает Kazakh; это не подтверждение CQA-accuracy.

[23] ISSAI Qwen3.5 9B Kazakh

Казахская адаптация для KZ challenger-эксперимента.

[24] vLLM Structured Outputs

Серверное constrained decoding для совместимых локальных моделей.

Проектные основания

Доступная локальная спецификация критерии_оценки.md; требования и официальное уточнение о звонках из задания; предоставленный DEV API с 65 записями. Документы конкуренты.md и пользователи_и_боли.md использованы как контекст, а не как доказательство точности моделей. Подписанные ссылки, контакты и персональные цитаты не включены.